

5.5 最佳近似和最小二乘

Def 5.1 (最佳估计) 给出了定义了距离的线性函数空间 Y 和它的子空间 $X \subset Y$, 称函数 $\hat{\varphi} \in X$ 是

(距离定义为 $\|\cdot\|$ 下) $f \in Y$ 在 X 中的最佳估计, 当且仅当 $\forall \varphi \in X, \|f - \hat{\varphi}\| \leq \|f - \varphi\|$

Ex 5.2 [Thm 2.4.6 切比雪夫定理] 给出了在模长定义为 $\|g\|_\infty = \max_{x \in [-1, 1]} |g(x)|$ 下, $f(x) = -x^n \in P_n(\mathbb{R})$ 在 $P_{n-1}(\mathbb{R})$

中的最佳估计是 $\hat{\varphi}(x) = \frac{T_n(x)}{2^{n-1}} - x^n$, T_n 是 n 次切比雪夫多项式.

Def 5.3 (基本线性估计问题) 给定函数 $f \in Y$ 和 n 个 X 中元素 $u_1, u_2, \dots, u_n \in X \subset Y$

寻找形如 $\hat{\varphi} = \sum_{i=1}^n a_i u_i$ 的最佳估计, $a_i \in \mathbb{R}$.

Ex 5.4 对于 $f(x) = e^x \in C^\infty[-1, 1]$, 寻找形如 $\hat{\varphi} = \sum_{i=1}^n a_i u_i \in X = \text{span}\{1, x, x^2, \dots\}$ 的最佳估计, 其中 n 为正整数,

$\|\cdot\|$ 定义为 ∞ -范数 $\|\cdot\|_\infty$, 1-范数或 2-范数, $\|g\|_1 = \int_{-1}^1 |g(x)| dx$, $\|g\|_2 = (\int_{-1}^1 |g(x)|^2 dx)^{\frac{1}{2}}$

注: 三种范数对应不同的误差, $\|\cdot\|_\infty$ 对应最小-最大误差, $\|\cdot\|_1$ 对应 $g(x)$ 与 x 轴围成的面积绝对误差

$\|\cdot\|_2$ 对应 $g(x)$ 与 0 的 (函数空间下的) 欧氏距离.

Ex 5.5 对简单闭曲线 $r: [0, 1] \rightarrow \mathbb{R}^2$ 和曲线上的 n 个点, $x_i \in r$, 考虑样条估计 $p: [0, 1] \rightarrow \mathbb{R}^2$, 结点为 x_i ,

总长度单位 1, 记 $\text{Int}(r)$ 为闭曲线 r 围成的区域, 记 $S_1 = \text{Int}(r)$, $S_2 = \text{Int}(p)$ 的面积差为

$\|S_1 \oplus S_2\| = \int_{S_1 \oplus S_2} d\vec{x}$, 其中 $S_1 \oplus S_2 = S_1 \cup S_2 \setminus (S_1 \cap S_2)$.

注: 称 $\|S_1 \oplus S_2\|$ 最小的样条估计为 r 在 1-范数下的最佳估计.

Thm 5.6 设 X 是内积空间 $(Y, \|\cdot\|)$ 的有限维子空间, 则有 $\forall y \in Y$, 定义 $B_y = \{x \in X: \|x\| \leq \|y\|\}$, 显然 $0 \in B_y$,

而 y 到 B_y 的距离为 $\text{dist}(y, B_y) = \inf_{x \in B_y} \|y - x\| \leq \|y - 0\| = \|y\|$, $\Rightarrow \exists \hat{\varphi} \in X$, s.t. $\forall \varphi \in X, \|\hat{\varphi} - y\| \leq \|\varphi - y\|$.

由定义 $\forall z \in X, z \notin B_y, \|z\| > \|y\|, \|z - y\| \geq \|z\| - \|y\| > \|y\|$

\therefore 若 y 的最佳估计存在, 一定在 B_y 中, $\because B_y \subset X \therefore B_y$ 是有限维的有界闭集, 因此是紧集

由连续函数在紧集上的极值定理, $d(x) = \|x - y\|$ 在 B_y 上取得极小值, 极小值点为 $\hat{\varphi} \in X$.

Thm 5.7 集合 $C[a, b]$ ($[a, b]$ 上全体连续函数) 是 \mathbb{C} 上的内积空间, 内积运算定义为 $\langle u, v \rangle = \int_a^b \rho(t) u(t) \overline{v(t)} dt$

其中 $\overline{v(t)}$ 是 $v(t)$ 的复共轭函数, 权重函数 $\rho(x) \in C[a, b]$ 满足 $\rho(x) > 0$, 且 $\|u\|_2 = (\int_a^b \rho(t) |u(t)|^2 dt)^{\frac{1}{2}}$

Def 5.8 称 $C[a, b]$ 上函数的最小均方估计是模长定义同 Thm 5.7 的最佳估计.

5.5.1 正交系统

Def 5.9 称内积空间 X 的子集 S 是正交的, 如果 $\forall u, v \in S, \langle u, v \rangle = \begin{cases} 0, & u \neq v \\ 1, & u = v \end{cases}$.

Ex 5.10 \mathbb{R}^n 上的标准基是正交的.

Ex 5.11 Def 2.4.1 中 $T_n(x) = \cos(n \arccos x)$ 是正交集, 其中 $[a, b] = [-1, 1]$, $\rho = \frac{1}{\sqrt{1-x^2}}$.

Thm 5.12 任何有限正交集的元素线性无关.

Def 5.13 Schmidt 正交化可将有限/无限线性无关组 (u_1, u_2, \dots) 转化为 (u_1^*, u_2^*, \dots)

$$v_{n+1} = u_{n+1} - \sum_{i=1}^n \langle u_{n+1}, u_i^* \rangle u_i^*, \quad u_{n+1}^* = \frac{v_{n+1}}{\|v_{n+1}\|}$$

Thm 5.14 对有限/无限的线性无关组 (u_1, u_2, \dots) , 施密特正交化过程给出了系数

$$\begin{matrix} a_{11} \\ a_{21} \ a_{22} \\ a_{31} \ a_{32} \ a_{33} \\ \vdots \end{matrix} \quad \text{s.t.} \quad a_{kk} = \frac{1}{\|u_k\|^2} > 0, \text{ 且 } \begin{cases} u_1^* = a_{11} u_1 \\ u_2^* = a_{21} u_1 + a_{22} u_2 \\ \dots \end{cases} \text{ 是正交的.}$$

Pf: 由Def 5.13归纳可知 u_k^* 是 u_1, \dots, u_k 的线性组合, 下用归纳法证明正交性, 若 $\forall m < n, k \leq m, \langle u_m^*, u_k^* \rangle = \begin{cases} 1, k=m \\ 0, k \neq m \end{cases}$

因为 $u_n^* = \frac{1}{\|u_n\|} (u_n - \sum_{j=1}^{n-1} \langle u_n, u_j^* \rangle u_j^*)$, 所以 $\forall k < n$,

$$\begin{aligned} \langle u_n^*, u_k^* \rangle &= \langle \frac{1}{\|u_n\|} (u_n - \sum_{j=1}^{n-1} \langle u_n, u_j^* \rangle u_j^*), u_k^* \rangle = \frac{1}{\|u_n\|} (\langle u_n, u_k^* \rangle - \sum_{j=1}^{n-1} \langle u_n, u_j^* \rangle \langle u_j^*, u_k^* \rangle) \\ &= \frac{1}{\|u_n\|} (\langle u_n, u_k^* \rangle - \langle u_n, u_k^* \rangle \langle u_k^*, u_k^* \rangle) = 0, \quad \langle u_n^*, u_n^* \rangle = \|u_n^*\| = 1 \end{aligned}$$

Cor 5.16 对有限/无限的线性无关组, 可找到系数

$$\begin{matrix} b_{11} \\ b_{21} \ b_{22} \\ \dots \end{matrix} \text{ 和正交集 } (u_1^*, u_2^*, \dots) \text{ s.t. } b_{ij} > 0 \text{ 且 } \begin{cases} u_1 = b_{11} u_1^* \\ u_2 = b_{21} u_1^* + b_{22} u_2^* \\ \dots \end{cases}$$

Pf: $u^* = Au, A$ 为下三角矩阵, 且对角元为正 $\Rightarrow A$ 可逆 $\Rightarrow u = A^{-1} u^*$

Cor 5.17 在Thm 5.14中, $\forall i=1, 2, \dots, n-1, \langle u_n^*, u_i^* \rangle = 0$

Def 5.18 在Thm 5.7的内积定义下, 对线性无关组 $(1, x, x^2, \dots)$ 进行Schmidt正交化过程,

分别在 $a, b, p(x)$ 下定义, 可得到如下标准多项式:

a	b	$p(x)$	正交多项式
-1	1	$1/\sqrt{1-x^2}$	第1类切比雪夫多项式
-1	1	$\sqrt{1-x^2}$	第2类切比雪夫多项式
-1	1	1	勒让德多项式
-1	1	$(1-x)^\alpha(1+x)^\beta$	亚可比多项式 ($\alpha, \beta > -1$)
0	$+\infty$	$x^\alpha e^{-x}$	拉盖尔多项式 ($\alpha > -1$)
$-\infty$	$+\infty$	e^{-x^2}	厄米特多项式

Ex 5.19 勒让德多项式的前三项.

$$u_1=1, v_1=1, \|v_1\|^2 = \int_{-1}^1 dx = 2 \quad u_1^* = \frac{1}{\sqrt{2}}$$

$$u_2=x, v_2=x - \langle x, \frac{1}{\sqrt{2}} \rangle \frac{1}{\sqrt{2}} = x \quad \|v_2\|^2 = \int_{-1}^1 x^2 dx = \frac{2}{3} \quad u_2^* = \frac{\sqrt{3}}{2} x$$

$$u_3=x^2, v_3=x^2 - \langle x^2, \frac{1}{\sqrt{2}} \rangle \frac{1}{\sqrt{2}} - \langle x^2, \frac{\sqrt{3}}{2} x \rangle \frac{\sqrt{3}}{2} = x^2 - \frac{1}{3} \quad \|v_3\|^2 = \int_{-1}^1 (x^2 - \frac{1}{3})^2 dx = \frac{8}{45} \quad u_3^* = \frac{\sqrt{5}}{2} (x^2 - \frac{1}{3})$$

5.5.2 傅里叶展开

Def 5.20 设 (u_k^*) 是有限/无限的正交集, 称 w 的正交展开或傅里叶展开为 $\sum_{k=1}^m \langle w, u_k^* \rangle u_k^* \quad (m \leq +\infty)$

其中系数 $\langle w, u_k^* \rangle$ 称为傅里叶系数, $\langle w, u_k^* \rangle u_k^*$ 称为 w 在 u_k^* 上的投影, 称为傅里叶展开的误差为 $\sum_{k=1}^m \langle w, u_k^* \rangle u_k^* - w$

Ex 5.21 在欧氏内积下, \mathbb{R}^3 的正交集为 $u_1^*=(1,0,0)^T, u_2^*=(0,1,0)^T, u_3^*=(0,0,1)^T$

对向量 $w=(a,b,c)^T$, 其傅里叶系数为 a, b, c , 傅里叶展开为 $w=au_1^*+bu_2^*+cu_3^*$, 误差为 0

Ex 5.22 对 $L^2[-\pi, \pi]$ 上的正交集 $\frac{1}{\sqrt{2\pi}}, \frac{\sin x}{\sqrt{\pi}}, \frac{\cos x}{\sqrt{\pi}}, \dots, \frac{\sin nx}{\sqrt{\pi}}, \frac{\cos nx}{\sqrt{\pi}}, f(x) \sim \frac{a_0}{2} + \sum_{k=1}^{+\infty} (a_k \cos kx + b_k \sin kx)$

$$\text{其中 } a_k = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \cos kx \, dx, \quad b_k = \frac{1}{\pi} \int_{-\pi}^{\pi} f(x) \sin kx \, dx$$

Thm 5.23 设 u_1, \dots, u_n 线性无关, $\{u_i^*\}$ 是 $\{u_i\}$ 经斯密特正交化得到的正交组

若 $w = \sum_{i=1}^n a_i u_i$, 则 $w = \sum_{i=1}^n \langle w, u_i^* \rangle u_i^*$

PF: 由 $w = \sum_{i=1}^n a_i u_i$ 及 Cor 5.16 得 $\exists c_1, \dots, c_n$ s.t. $w = \sum_{i=1}^n c_i u_i^*$, 由 $\{u_i^*\}$ 线性无关, $c_i = \langle w, u_i^* \rangle$

Thm 5.24 (Fourier 级数的最小性) 设 u_1^*, \dots, u_n^* 是正交系统, 则 $\|w - \sum_{i=1}^n \langle w, u_i^* \rangle u_i^*\| \leq \|w - \sum_{i=1}^n a_i u_i^*\| \quad \forall a_i$

PF: $\|w - \sum_{i=1}^n a_i u_i^*\|^2 = \langle w - \sum_{i=1}^n a_i u_i^*, w - \sum_{i=1}^n a_i u_i^* \rangle = \langle w, w \rangle - \langle w, \sum_{i=1}^n a_i u_i^* \rangle - \langle \sum_{i=1}^n a_i u_i^*, w \rangle + \sum_{i,j=1}^n a_i \bar{a}_j \langle u_i^*, u_j^* \rangle$
 $= \langle w, w \rangle - \sum_{i=1}^n \bar{a}_i \langle w, u_i^* \rangle - \sum_{i=1}^n a_i \langle u_i^*, w \rangle + \sum_{i=1}^n |a_i|^2 = \|w\|^2 - \sum_{i=1}^n |\langle w, u_i^* \rangle|^2 + \sum_{i=1}^n |a_i - \langle w, u_i^* \rangle|^2$

Cor 5.25 设 $\{u_1, u_2, \dots, u_n\}$ 是线性无关组, 则 w 的最佳线性估计是 $\hat{w} = \sum_{i=1}^n \langle w, u_i^* \rangle u_i^*$,

其中 $\{u_i^*\}$ 是 $\{u_i\}$ 经过斯密特正交化得到的正交化得到正交组, 误差为 $\|w - \hat{w}\|^2 = \min_{a_i} \|w - \sum_{i=1}^n a_i u_i\|^2$

Cor 5.26 (贝塞尔不等式) 若 $u_1^*, u_2^*, \dots, u_n^*$ 正交, 则 $\|w\|^2 \geq \sum_{i=1}^n |\langle w, u_i^* \rangle|^2 = \|w - \sum_{i=1}^n \langle w, u_i^* \rangle u_i^*\|^2$

Cor 5.27 Def 5.1 中斯密特正交化的过程满足 $n \in \mathbb{N}^+$, $\|u_{n+1}\|^2 = \|u_n\|^2 - \sum_{i=1}^n |\langle u_n, u_i^* \rangle|^2$

Ex 5.28 考虑 5.4 在 $a=-1, b=1, \rho=1$ 的内积定义下求均方误差最小的线性估计. 即 $\min_{a_i} \int_{-1}^1 |e^x - \sum_{i=1}^n a_i x^i|^2 dx$

对 $n=1, 2$, 由 Ex 5.19 中求得的勒让德多项式 $u_1^* = \frac{1}{\sqrt{2}}, u_2^* = \frac{\sqrt{3}}{2}x, u_3^* = \frac{\sqrt{5}}{2}(3x^2-1)$

e^x 的傅里叶系数为 $b_1 = \int_{-1}^1 \frac{1}{\sqrt{2}} e^x dx = \frac{1}{\sqrt{2}}(e - \frac{1}{e})$, $b_2 = \int_{-1}^1 \frac{\sqrt{3}}{2} x e^x dx = \frac{\sqrt{3}}{2} e^{-1}$, $b_3 = \int_{-1}^1 \frac{\sqrt{5}}{2} (3x^2-1) e^x dx = \frac{\sqrt{5}}{2} (e - \frac{1}{e})$

$\hat{\varphi}_n = \begin{cases} \frac{1}{\sqrt{2}}(e^2-1) + \frac{1}{\sqrt{2}}x, & n=1 \\ \frac{1}{\sqrt{2}}(e^2-1) + \frac{1}{\sqrt{2}}x + \frac{1}{\sqrt{2}}(e^2-7)(3x^2-1), & n=2 \end{cases}$

§ 5.3 正则方程组.

Thm 5.29 设 $u_1, u_2, \dots, u_n \in X$ 线性无关, u_i^* 是 u_i 经斯密特正交化后的正交基, 则

$\forall w, \forall j=1, \dots, n \quad (w - \sum_{i=1}^n \langle w, u_i^* \rangle u_i^*) \perp u_j^*$

PF: 若 $w \in X$, 则 $w - \sum_{i=1}^n \langle w, u_i^* \rangle u_i^* = 0$.

若 $w \notin X$, 令 $w = u_{n+1}$ 并对 u_{n+1} 作斯密特正交化, 则 $u_{n+1}^* = \frac{w - \sum_{i=1}^n \langle w, u_i^* \rangle u_i^*}{\|u_{n+1}\|} \perp u_i^*, i=1, \dots, n$ 由 Cor 5.17

Cor 5.30 设 $u_1, \dots, u_n \in X$ 线性无关, 若 $\hat{w} = \sum_{i=1}^n a_i u_i$ 是 w 的最佳线性估计, 则 $\forall j=1, \dots, n, (w - \hat{w}) \perp u_j$

PF: $\hat{w} = \sum_{i=1}^n a_i u_i = \sum_{i=1}^n \langle w, u_i^* \rangle u_i^*$, 由 Thm 5.29 $(w - \hat{w}) \perp u_j^*, j=1, \dots, n$, 由 Cor 5.16 $(w - \hat{w}) \perp u_j, j=1, \dots, n$

Def 7.31 设 u_1, \dots, u_n 是内积空间的一组元素, 则记 $n \times n$ 矩阵 $G = G(u_1, \dots, u_n) = (\langle u_i, u_j \rangle)_{n \times n}$ 为 u_1, \dots, u_n 的 Gram 矩阵, 记 $g = g(u_1, \dots, u_n) = \det G$ 为 Gram 行列式.

lem 5.32 设 $w_i = \sum_{j=1}^n a_{ij} u_j, i=1, 2, \dots, n, A = (a_{ij})_{n \times n}, A^H = (\bar{a}_{ji})_{n \times n}$ 则 $\begin{cases} G(w_1, \dots, w_n) = A G(u_1, \dots, u_n) A^H \\ g(w_1, \dots, w_n) = |\det A|^2 g(u_1, \dots, u_n) \end{cases}$

PF: $G(w_1, \dots, w_n) = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} \langle u_1, w_1 \rangle & \dots & \langle u_1, w_n \rangle \\ \vdots & & \vdots \\ \langle u_n, w_1 \rangle & \dots & \langle u_n, w_n \rangle \end{bmatrix} = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} \langle u_1, u_1 \rangle & \dots & \langle u_1, u_n \rangle \\ \vdots & & \vdots \\ \langle u_n, u_1 \rangle & \dots & \langle u_n, u_n \rangle \end{bmatrix} \begin{bmatrix} \bar{a}_{11} & \dots & \bar{a}_{1n} \\ \vdots & & \vdots \\ \bar{a}_{n1} & \dots & \bar{a}_{nn} \end{bmatrix} = A G(u_1, \dots, u_n) A^H$

$\det |G(w_1, \dots, w_n)| = \det A \cdot \det G(u_1, \dots, u_n) \cdot \det A^H = \det A \det \bar{A} g(u_1, \dots, u_n) = |\det A|^2 g(u_1, \dots, u_n)$

Thm 5.33 对非0元素 $u_1, u_2, \dots, u_n \in X$, $0 \leq g(u_1, \dots, u_n) \leq \prod_{k=1}^n \|u_k\|^2$

左不等号成立当且仅当 u_1, \dots, u_n 线性相关, 右不等号成立当且仅当 u_1, \dots, u_n 正交.

PF: 若 u_1, \dots, u_n 线性相关, 则 $\exists c_1, \dots, c_n, \sum_{i=1}^n c_i u_i = 0, [c_1, \dots, c_n]^T \neq 0$. 不妨设 $c_j \neq 0$.

$$\text{令 } w_k = \begin{cases} \frac{1}{c_j} \sum_{i=1}^n c_i u_i = 0, & k=j \\ u_k, & k \neq j \end{cases}, \text{ 则 } g(w_1, \dots, w_n) = 0, \text{ 而 } w = Cn, C = \begin{bmatrix} 1 & & \\ & \ddots & \\ c_1 & c_2 & \dots & c_n \\ & & & 1 \end{bmatrix}, \det C = c_j \neq 0$$

$$\text{因此 } g(u_1, \dots, u_n) = \frac{g(w_1, \dots, w_n)}{|\det C|^2} = 0.$$

若 u_1, \dots, u_n 线性无关, 由 Thm 5.14 可知 \exists 正交组 $\{u_i^*\}$, s.t. $u_i^* = \sum_{j=1}^n a_{ij} u_j$

由定义 $g(u_1^*, \dots, u_n^*) = 1$ 又 $\det(A) = \prod_{k=1}^n a_{kk} \therefore g(u_1, \dots, u_n) = \prod_{k=1}^n \frac{1}{a_{kk}^2} > 0$. 左不等号即取等条件得证.

若 u_1, \dots, u_n 正交, $g(u_1^*, \dots, u_n^*) = \det \text{diag}(\|u_i\|^2) = \prod_{k=1}^n \|u_k\|^2$

反之, 若 $g(u_1, \dots, u_n) = \prod_{k=1}^n \|u_k\|^2$, 则 u_1, \dots, u_n 一定线性无关.

对 (u_1, \dots, u_n) 应用 schmidt 正交化, 由 Thm 5.14 得 $\|u_k\|^2 = \sum_{j=1}^{k-1} |<u_k, u_j^*>|^2 + \|u_k^*\|^2$. 分别对前 $1, 2, \dots, n$ 个 u_k 应用 Thm 5.14

得 $\|u_k\|^2 = \|u_k^*\|^2$, 由 Cor 5.27, $\forall k=1, 2, \dots, n, \sum_{j=1}^{k-1} |<u_k, u_j^*>|^2 = 0 \therefore u_k$ 正交

且由 Cor 5.27 得 $g(u_1, \dots, u_n) = \prod_{k=1}^n \frac{1}{a_{kk}^2} = \prod_{k=1}^n \|u_k\|^2 = \prod_{k=1}^n (\|u_k\|^2 - \sum_{j=1}^{k-1} |<u_k, u_j^*>|^2) = \prod_{k=1}^n \|u_k\|^2$, 右也得证.

Thm 5.34 设 $\hat{p} = \sum_{i=1}^n a_i u_i$ 是 w 在 $\text{span}\{u_1, \dots, u_n\}$ 中的最佳线性估计, 则系数 $a = (a_1, a_2, \dots, a_n)^T$ 由正则方程组

$$G(u_1, \dots, u_n) a = C, C = [<w, u_1>, \dots, <w, u_n>]^T \text{ 唯一确定.}$$

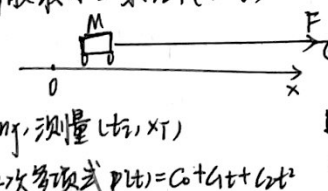
PF: 由 Cor 5.30 $<\hat{p}, u_j> = <w, u_j> = \sum_{i=1}^n a_i <u_i, u_j>, \forall j=1, \dots, n$, 取立 n 个方程.

Ex 5.35 求 e^x 在 $\text{span}\{x, x^2\}$ 中的最佳线性估计.

$$G(x, x^2) = \begin{bmatrix} <x, x> & <x, x^2> \\ <x^2, x> & <x^2, x^2> \end{bmatrix} = \begin{bmatrix} \frac{2}{3} & 0 \\ 0 & \frac{2}{5} \end{bmatrix}, C = \begin{bmatrix} <e^x, x> \\ <e^x, x^2> \end{bmatrix} = \begin{bmatrix} \frac{1}{e} \\ \frac{2}{e} \end{bmatrix} \text{ 解得 } \begin{cases} a_0 = \frac{3(1-e^2)}{4e} \\ a_1 = \frac{3}{e} \\ a_2 = \frac{15(e^2-7)}{4e} \end{cases}$$

Ex 5.36 对于 $f \in C[0,1]$ 在 $\text{span}\{x, x^2, \dots\}$ 求最小二乘估计, 则 $<x^j, x^k> = \int_0^1 x^j x^k dx = \frac{1}{j+k+1}$ 为希尔伯特矩阵

5.4 离散最小二乘法 (DLS)

Ex 5.36  $m_j g = (m_j + M) a = (m_j + M) \frac{d^2 x}{dt^2}$

(1) 定 m, m_j , 测量 (t_i, x_i)

(2) 拟合二次多项式 $p(t) = c_0 + c_1 t + c_2 t^2$

使 $\sum (x_i - p(t_i))^2$ 最小

(3) 取 $a_j = 2c_2$ 作为加速度的测量值, $F_j = m_j(g - a_j)$

(4) 改变 m_j , 重复 (1)~(3), 得到若干 (a_j, F_j)

(5) 拟合出一阶多项式 $f(x) = c_0 + c_1 x$, 使 $\sum (F_j - f(a_j))^2$ 最小.

最终得到 M 近似值 c_1

* (2) 与 (5) 为 "最小二乘问题"

§5.4.1 高斯函数和 Dirac delta 函数.

Def 5.38 Gauss 函数形如 $f(x) = a \exp\left\{-\frac{(x-b)^2}{2c^2}\right\}$

lem 5.39 Gauss 函数的积分: $\int_{-\infty}^{+\infty} a \exp\left\{-\frac{(x-b)^2}{2c^2}\right\} dx = ac\sqrt{2\pi}$

Def 5.40 正态分布(高斯分布): $f_{\mu, \sigma} = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$

Def 5.41 中心在 \bar{x} 的 Dirac delta 函数, $\delta(x-\bar{x}) = \lim_{\varepsilon \rightarrow 0} \phi_\varepsilon(x-\bar{x})$, 其中 $\phi_\varepsilon(x-\bar{x}) = \frac{1}{\varepsilon} \chi_{[\bar{x}-\varepsilon, \bar{x}+\varepsilon]}$

lem 5.42 Dirac delta 函数满足 $\delta(x-\bar{x}) = \begin{cases} +\infty, & x=\bar{x} \\ 0, & x \neq \bar{x} \end{cases} \quad \int_{-\infty}^{+\infty} \delta(x-\bar{x}) dx = 1$

lem 5.43 (δ 的筛选性) 设 $f: \mathbb{R} \rightarrow \mathbb{R}$ 连续, 则 $\int_{-\infty}^{+\infty} \delta(x-\bar{x}) f(x) dx = f(\bar{x})$

PF: $\forall \varepsilon > 0, \int_{-\infty}^{+\infty} \delta(x-\bar{x}) f(x) dx = \int_{\bar{x}-\varepsilon}^{\bar{x}+\varepsilon} \delta(x-\bar{x}) f(x) dx = f(\xi_\varepsilon) \int_{\bar{x}-\varepsilon}^{\bar{x}+\varepsilon} \delta(x-\bar{x}) dx = f(\xi_\varepsilon) \quad \xi_\varepsilon \in [\bar{x}-\varepsilon, \bar{x}+\varepsilon]$

令 $\varepsilon \rightarrow 0$ 则 $\int_{-\infty}^{+\infty} \delta(x-\bar{x}) f(x) dx = f(\bar{x})$

Def 5.44 Heaviside 函数/阶梯函数 $H(x) = \begin{cases} 0, & x < 0 \\ 1, & x > 0 \end{cases}$

lem 5.45 $H(x) = \int_{-\infty}^x \delta(t) dt$

§5.4.2 离散测度

Def 5.46 定义函数 $\lambda: \mathbb{R} \rightarrow \mathbb{R}, \lambda(t) = \begin{cases} 0, & t \in (-\infty, a) \\ \int_a^t \rho(\tau) d\tau, & t \in [a, b] \\ \int_a^b \rho(\tau) d\tau, & t \in (b, +\infty) \end{cases}; d\lambda(t) = \begin{cases} \rho(t) dt, & t \in [a, b] \\ 0, & \text{otherwise} \end{cases}$

Def 5.47 称点集 $\{t_1, t_2, \dots, t_n\}$ 的离散测度或 Dirac 测度为 $d\lambda(t) = \sum_{i=1}^n \rho_i \delta(t-t_i) dt$

相应地, $\lambda(t) = \sum_{i=1}^n \rho_i H(t-t_i)$

lem 5.48 设 $u: \mathbb{R} \rightarrow \mathbb{R}$, 定义 $\lambda(t) = \sum_{i=1}^n \rho_i H(t-t_i)$, 则 $\int_{\mathbb{R}} u(t) d\lambda = \sum_{i=1}^n \rho_i u(t_i)$

PF: $\int_{\mathbb{R}} u(t) d\lambda = \int_{\mathbb{R}} \sum_{i=1}^n \rho_i \delta(t-t_i) u(t) dt = \sum_{i=1}^n \rho_i u(t_i)$

§5.4.3 DLS 和正则方程组.

Ex 5.49 考虑如下数据.

x	1	2	3	4	5	6	7	8	9	10	11	12
y	256	201	159	61	77	40	17	28	103	156	222	245

拟合二次多项式 $\sum_{j=0}^2 a_j x^j$ 使 $\sum_{i=1}^{12} (y_i - \sum_{j=0}^2 a_j x_i^j)^2$ 最小

解: 定义内积 $\langle f, g \rangle = \sum_{i=1}^{12} f(x_i) g(x_i)$, $G(x, x') = (\langle x^j, x'^j \rangle)_{3 \times 3}$, $C = \begin{bmatrix} \langle y, 1 \rangle \\ \langle y, x \rangle \\ \langle y, x^2 \rangle \end{bmatrix}$, $a = G^{-1}C$

§5.4.3 DLS 的 QR 分解法

Def 5.50 称 $A \in \mathbb{R}^{n \times n}$ 正交 $\Leftrightarrow A^T A = I$

Def 5.51 称 $A \in \mathbb{R}^{n \times n}$ 上三角 $\Leftrightarrow \forall i < j, a_{ij} = 0$, 下三角 $\Leftrightarrow \forall i > j, a_{ij} = 0$

Thm 5.52 (QR 分解) $\forall A \in \mathbb{R}^{m \times n}$, \exists 正交阵 Q 和上三角阵 R s.t. $A = QR$

PF: 记 $A = [\beta_1, \dots, \beta_n] \in \mathbb{R}^{m \times n}$, 按如下步骤构造秩为 $r(A)$ 的矩阵 $A_r = [u_1, \dots, u_r]$

(1) 令 $u_1 = \xi_1$, k_1 满足 $\xi_{k_1} \neq 0, \forall 1 < k_1, \xi_0 = 0$.
 (2) $\forall j = 2, \dots, r$ 令 $u_j = \xi_{k_j}$, k_j 满足 $k_j = \{k_1, \dots, k_{j-1}\}$ 线性无关; $\forall 1 = k_1 + 1, \dots, k_{j-1}$, ξ_i 可由 k_{j-1} 线性表示

\Rightarrow 选出线性无关的 r 列.

由 Cor 7-16, 斯密特正交化过程给出了唯一的正交阵 $A^* = [u_1^*, \dots, u_r^*] \in \mathbb{R}^{n \times r}$ 和上三角阵 $(b_{ij})_{r \times r}$

4. $A_r = A_r^* \begin{bmatrix} b_{11} & b_{12} & \dots & b_{1r} \\ & b_{22} & & b_{2r} \\ & & \ddots & \\ & & & b_{rr} \end{bmatrix}$, $r \leq m$. 接下来将第 r 列插入, 对于全列 ξ_1, \dots, ξ_{r-1} $[\xi_1, \dots, \xi_{r-1}, u_1, \dots, u_r] = A_r^* \begin{bmatrix} b_{11} & \dots & b_{1r} \\ \vdots & & \vdots \\ b_{r-1,1} & \dots & b_{r-1,r} \end{bmatrix}$

对于 $p = k_j + 1, \dots, k_{j+1} - 1$ 到 $[u_1, \dots, u_{j+1}, z_i] = [u_1^*, \dots, u_{j+1}^*]$ $\begin{bmatrix} b_{11} & \dots & b_{1j} & c_1 \\ & \ddots & \vdots & \vdots \\ & & b_{j+1,j} & c_{j+1} \\ \hline & & & 0 \end{bmatrix}$, 由此可构造 $A = A^* R$.

lem 9.5 正交阵是保2-测度的, 即 $\forall x \in \mathbb{R}^n$, \forall 正交阵 $Q \in \mathbb{R}^{n \times n}$, $\|Qx\|_2 = \|x\|_2$

PF: $\|Qx\|_2^2 = x^T Q^T Q x = x^T x = \|x\|_2^2$

Thm 5.54 考虑超定线性方程组 $AX=b$, $A \in \mathbb{R}^{m \times n}$, $m > n$, 则离散最小二乘问题 $\min_{x \in \mathbb{R}^n} \|Ax-b\|_2^2$ 的解 x^* 为 $Rx^*=C$ 的解, 其中 $R \in \mathbb{R}^{n \times n}$, $C \in \mathbb{R}^n$, 满足 $R^T A = R$, $R = \begin{bmatrix} P \\ 0 \end{bmatrix}$, $R^T b = \begin{bmatrix} C \\ r \end{bmatrix}$

PF: $\forall x \in \mathbb{R}^n, \|Ax - b\|_2^2 = \|Q^T Ax - Q^T b\|_2^2 = \|R_1 x - c\|_2^2 + \|r\|_2^2$

5.5 解决 ill-posed 线性系统

Def 7.5 称一个问题为 well-posed 的: (i) 有一个解 (ii) 解唯一 (iii) 条件数小. 否则, 该问题为 ill-posed.

lem 5.56 (线性系统的可解性) $A \in \mathbb{C}^{m \times n}$ 的线性系统 $Ax=b$ 有解, 当且仅当 b 在 A 的范围内, 或等价地说, b 在 A 的伴随矩阵的零空间垂直, 即 $\forall z \in \{y \in \mathbb{C}^m : A^*y=0\}, \langle b, z \rangle = 0$

在这种情况下, 一个特解为 $x^{(0)} = \sum_{j=1}^r \frac{1}{\sigma_j} \langle b, v_j \rangle u_j$, 其中 r 为 A 的秩, $\langle b, v_j, u_j \rangle$ 为其奇异值和奇异向量.

PF: 若 $\exists x \in \mathbb{C}^n, Ax=b$, 则 $\langle b, z \rangle = \langle Ax, z \rangle = \langle x, A^*z \rangle = 0$

若 $\forall z \in \{y \in \mathbb{C}^m; A^*y=0\}, \langle b, z \rangle = 0$, 则 $b = \sum_{j=1}^r \langle b, v_j \rangle v_j = \sum_{j=1}^r \frac{1}{\|v_j\|^2} \langle b, v_j \rangle A u_j = A x$

5.5.1 无解或多解

Thm 5.57 假设 Lem 5.56 中 $AX=b$ 无解, 则 x^0 为其最小二乘问题的解, $x^0 = \arg \min_{x \in \mathbb{R}^n} \|Ax-b\|^2$

PF: b 的傅里叶展开为 $b = \sum_{j=1}^m \langle b, v_j \rangle v_j$, $\forall b \in \text{range } A$, $Ax^0 - b \in \text{span}(v_{r+1}, \dots, v_m)$

由A的秩为r, $\forall x \in \mathbb{C}^n$, $Ax - Ax^{\oplus} \in \text{span}\{v_1, \dots, v_r\}$, 因此 $\langle Ax^{\oplus} - b, Ax - Ax^{\oplus} \rangle = 0$

由毕达哥拉斯定理, $\|Ax - b\|_2^2 = \|Ax - Ax^\oplus\|_2^2 + \|Ax^\oplus - b\|_2^2$

Thm 5.58 若 $Ax=b$ 有多解, 则通解为 $y+x^0$, $y \in \text{null } A$, 且 x^0 为具有最小 2-范数的解.

pf: 由 Lem 9.56 $X^\oplus \in \text{span}(u_1, \dots, u_r)$, $\text{null } A = \text{span}(u_{r+1}, \dots, u_n)$. 因此 $\forall y \in \text{null } A$, $\langle X^\oplus, y \rangle = 0$

由毕达哥拉斯定理 $\|x^0 + y\|_2 = \|x^0\|_2 + \|y\|_2$

§5.5.2 The Moore-Penrose inverse

Def 5.59 矩阵 $A \in \mathbb{F}^{m \times n}$ ($\mathbb{F} = \mathbb{R}, \mathbb{C}$) 的 ^{pseudo} Moore-Penrose 逆为 $A^+ \in \mathbb{F}^{n \times m}$. $A^+ y = \sum_{j=1}^r \frac{1}{\sigma_j} \langle y, v_j \rangle u_j$
generalized

Thm 5.60 A^+ 满足以下性质:

(PDI-1) $AA^+A = A$ (PDI-2) $A^+AA^+ = A^+$ (PDI-3) $(AA^+)^* = AA^+$, $(A^+A)^* = A^+A$, 即为 Hermitian 阵

lem 5.61 若 A 的列向量线性无关, 则 A^*A 可逆且 $A^+ = (A^*A)^{-1}A^*$, $A^+A = I$

若 A 的行向量线性无关, 则 AA^* 可逆, 且 $A^+ = A^*(AA^*)^{-1}$, $AA^+ = I$.

§5.5.3 Spectral cutoff for ill-conditioning

Ex 5.62 求解 $Ax = b$ 的条件数受小奇异值支配, 对 $\varepsilon \in \mathbb{C}$, 将 b 扰动为 $\hat{b} = b + \varepsilon v_j$, 由 lem 5.56, 解将变为 $\hat{x} = x + \frac{\varepsilon}{\sigma_j} u_j$, 基于绝对误差的条件数为 $\frac{\|\hat{x} - x\|_2}{\|\hat{b} - b\|_2} = \frac{1}{\sigma_j}$, 因此若其奇异值很小, 则问题为病态.

Def 5.63 谱截止 (spectral cutoff) 是通过忽略解 x 中奇异值较小的项来使病态问题更稳定的方法.

Def 5.64 给定 $Ax = b$ 的扰动 \hat{b} , 差异原理 (discrepancy principle) 是一种得出近似解的策略, 使得

$$\|A\hat{x} - \hat{b}\|_2 = C\|b - \hat{b}\|_2, \text{ 其中 } C \geq 1 \text{ 为一个合适的常数.}$$

Ex 5.65 对于谱截止, $x_p = \begin{cases} 0, & p=0 \\ \sum_{j=1}^p \frac{1}{\sigma_j} \langle \hat{b}, v_j \rangle u_j, & p=1, \dots, r \end{cases}$ 其中 p 由 $\|b - \hat{b}\|_2$ 决定, 常令 $C=1$.

Thm 5.66 $A \in \mathbb{C}^{m \times n}$, 线性方程组 $Ax = b$ 可解, $\|\hat{b} - b\|_2 \leq \varepsilon \leq \|b\|_2$, 则存在一个最小的 $p = p(\varepsilon)$ 使得 $\|A x_p - \hat{b}\|_2 \leq \varepsilon$
谱截止的差异原理是收敛的, 即 $\lim_{\varepsilon \rightarrow 0} x_p = A^+ b$.

PF: 定义 $f: \{0, 1, \dots, r\} \rightarrow \mathbb{R}$, $f(p) = \|A x_p - \hat{b}\|_2^2 - \varepsilon^2 = \sum_{j=p+1}^r |\langle \hat{b}, v_j \rangle|^2 - \varepsilon^2$, v_j 为 A 的右奇异向量.

$$f(0) = \|b\|_2^2 - \varepsilon^2 \geq 0, f(r) = -\varepsilon^2 < 0 \quad (r=m)$$

$$\text{若 } r < m, \text{ 由 lem 5.56, } b_j = 0, j=r+1, \dots, m, \langle b, v_j \rangle = 0, f(r) = \sum_{j=r+1}^m |\langle \hat{b} - b, v_j \rangle|^2 - \varepsilon^2 \leq \|\hat{b} - b\|_2^2 - \varepsilon^2 \leq 0$$

f 单调递减, $f(0) \geq 0, f(r) \leq 0$, 则 $\exists p, \|A x_p - \hat{b}\|_2 \leq \varepsilon$

$$\|A x_p - b\|_2 \leq \|A x_p - \hat{b}\|_2 + \|\hat{b} - b\|_2 \leq 2\varepsilon, \quad \forall v \in \text{span}(v_1, \dots, v_r) \quad A^+ A v = v \quad \therefore \lim_{\varepsilon \rightarrow 0} x_p = A^+ b.$$

§5.5.4 Tikhonov 正则化

Def 5.67 (Tikhonov 正则化) 通过正则化线性方程组 $\alpha x + A^* A x = A^* b$ 估计病态最小二乘问题 $Ax = b$ 的解. $\alpha > 0$ 称为正则化系数.

Thm 5.68 设矩阵 $A \in \mathbb{C}^{m \times n}$ 的秩为 r , 则对任意 $b \in \mathbb{C}^m$, Tikhonov 正则化有唯一解.

$$x_\alpha = \sum_{j=1}^r \frac{\sigma_j}{\alpha + \sigma_j^2} \langle b, v_j \rangle u_j. \text{ 进一步的 Tikhonov 正则化满足 } \lim_{\alpha \rightarrow 0} (\alpha I + A^* A)^{-1} A^* b = A^+ b.$$

PF: $B = \alpha I + A^* A$ 严格正定, 故非奇异, 且 $B u_j = (\alpha I + A^* A) u_j = \alpha u_j + A^* A u_j = \alpha u_j + \sigma_j^2 v_j = (\alpha + \sigma_j^2) u_j$

$B^* = B \Rightarrow (\alpha + \sigma_j^2, u_j, u_j)$ 为 B 的奇异值, 左奇异向量, 右奇异向量.

$$\text{将 lem 5.56 应用于 } \alpha x + A^* A x = A^* b \text{ 得 } x = \sum_{j=1}^r \frac{1}{\alpha + \sigma_j^2} \langle A^* b, u_j \rangle u_j = \sum_{j=1}^r \frac{\sigma_j}{\alpha + \sigma_j^2} \langle b, v_j \rangle u_j = x_\alpha$$

Thm 5.69 $\forall b \in \mathbb{C}^m$, Tikhonov 正则化的解 x_α 等价于 $\|Ax - b\|_2^2 + \alpha \|x\|_2^2$ 的最小值点.

PF: 令 $z_\alpha = \alpha x_\alpha + A^*Ax_\alpha - A^*b$, 由余弦定理,

$$\|Ax - b\|_2^2 + \alpha \|x\|_2^2 = 2\operatorname{Re}\langle x - x_\alpha, z_\alpha \rangle + \|Ax_\alpha - b\|_2^2 + \alpha \|x_\alpha\|_2^2 + \|A^*Ax_\alpha\|_2^2 + \alpha \|x - x_\alpha\|_2^2$$

$$\text{注: } 2\operatorname{Re}\langle Ax - Ax_\alpha, Ax_\alpha - b \rangle + 2\alpha \operatorname{Re}\langle x - x_\alpha, x_\alpha \rangle = 2\operatorname{Re}\langle x - x_\alpha, A^*(Ax_\alpha - b) + \alpha x_\alpha \rangle = 2\operatorname{Re}\langle x - x_\alpha, z_\alpha \rangle$$

因此 x_α 满足 $z_\alpha = 0$, 另一方面, 设 x_α 满足 $z_\alpha \neq 0$ 且是 $\|Ax - b\|_2^2 + \alpha \|x\|_2^2$ 的最小值点.

$$\text{则对 } x = x_\alpha - \varepsilon z_\alpha, \varepsilon \in \mathbb{R} \quad \|Ax - b\|_2^2 + \alpha \|x\|_2^2 = \|Ax_\alpha - b\|_2^2 + \alpha \|x_\alpha\|_2^2 - 2\varepsilon a + \varepsilon^2 b, \quad a = \|z_\alpha\|_2^2, \quad b = \|Az_\alpha\|_2^2 + \alpha \|z_\alpha\|_2^2$$

取 $\varepsilon = \frac{a}{b}$, 则 $\|Ax - b\|_2^2 + \alpha \|x\|_2^2 < \|Ax_\alpha - b\|_2^2 + \alpha \|x_\alpha\|_2^2$ 与 x_α 的最小性矛盾.

Ex 5.70 在实际应用中, 右端项通常不精确 (在某个范围内), 例如 $\|\hat{b} - b\|_2 < \varepsilon$

此时 Tikhonov 正则化对真解 $x = A^+b$ 的估计 x_α 满足 $Bx_\alpha = A^+\hat{b}$ ($B = \alpha I + A^*A$)

故总绝对误差为 $x_\alpha - x = B^{-1}A^*(\hat{b} - b) + (B^{-1}A^*b - A^+b)$ (第1项来自 $\hat{b} - b$, 第2项来自正则化)

另一方面, 由 Lem 4.68 得 $\operatorname{cond}_2 B = \frac{\alpha + \sigma_1^2}{\alpha + \sigma_n^2}$, 为使 $\operatorname{cond}_2 B$ 小, α 应尽量大, 注意这个结论对 Ex 5.62 中绝对误差的定义同样成立, α 应适当选择, 以保证精确性 (α 不能太大) 和稳定性 (α 不能太小)

Thm 5.71 设线性方程组 $Ax = b$, $A \in \mathbb{C}^{m \times n}$ 可解, b 的测量值 \hat{b} 满足 $\|\hat{b} - b\|_2 \leq \varepsilon \leq \|\hat{b}\|_2$

则存在唯一 $\alpha = \alpha(\varepsilon)$ s.t. $\|Ax_\alpha - \hat{b}\|_2 = \varepsilon$, 其中 x_α 是 $(\alpha I + A^*A)x = A^*\hat{b}$ 的唯一解.

进一步地, Tikhonov 正则化的误差原则是收敛的, 即 $\lim_{\varepsilon \rightarrow 0} x_\alpha = A^+b$

$$\text{PF: 由 Thm 5.68 } f(\alpha) = \|Ax_\alpha - \hat{b}\|_2^2 - \varepsilon^2 = \sum_{j=1}^m \left| \frac{\alpha^2}{\alpha^2 + \sigma_j^2} \right| \langle \hat{b}, v_j \rangle^2 - \varepsilon^2$$

其中 v_j 是 A 的右奇异向量, f 是连续单增函数且 $\lim_{\alpha \rightarrow 0} f(\alpha) = -\varepsilon^2 < 0$, $\lim_{\alpha \rightarrow \infty} f(\alpha) = \|\hat{b}\|_2^2 - \varepsilon^2 > 0$

故 f 有唯一根. $\exists! \alpha = \alpha(\varepsilon)$ s.t. $\|Ax_\alpha - \hat{b}\|_2 = \varepsilon$

$$\|\hat{b}\|_2 - \varepsilon = \|\hat{b}\|_2 - \|Ax_\alpha - \hat{b}\|_2 \leq \|Ax_\alpha\|_2,$$

$$\text{另一方面 } (\alpha I + A^*A)x_\alpha = A^*\hat{b} \quad \therefore \alpha \|Ax_\alpha\|_2 = \|AA^*(\hat{b} - Ax_\alpha)\|_2 \leq \|AA^*\|_2 \varepsilon$$

由 $\|\hat{b}\|_2 > \|\hat{b}\|_2 - \varepsilon$, 结合上2个不等式.

$$\alpha \leq \frac{\|AA^*\|_2 \varepsilon}{\|AA^*\|_2 \varepsilon} \leq \frac{\|AA^*\|_2 \varepsilon}{\|\hat{b}\|_2 - 2\varepsilon} \quad \text{故 } \lim_{\varepsilon \rightarrow 0} \alpha = 0 \quad \lim_{\varepsilon \rightarrow 0} x_\alpha = \lim_{\alpha \rightarrow 0} x_\alpha = \lim_{\alpha \rightarrow 0} \sum_{j=1}^r \frac{\sigma_j}{\alpha^2 + \sigma_j^2} \langle \hat{b}, v_j \rangle v_j = \sum_{j=1}^r \frac{1}{\sigma_j} \langle \hat{b}, v_j \rangle v_j = A^+b$$